

Jurnal etapa 2 – Ricu Alexandru Razvan

Cerinte rezolvate

În această etapă am realizat containerizarea completă a proiectului folosind Docker și docker-compose. Au fost create trei imagini: una pentru Ollama, una pentru serverul MCP și una pentru ADK-Web împreună cu agentul. Serverul MCP a fost extins cu un mecanism de autentificare pe baza de token-uri, astfel încât doar agenții autorizați să poată accesa tool-urile expuse. Toate aceste servicii au fost orchestrate printr-un fișier docker-compose, ceea ce permite pornirea sistemului cu o singură comandă și asigură comunicarea corespunzătoare între ele.

Modul de rezolvare

Pentru a containeriza modelul LLM, am creat o imagine dedicată care instalează Ollama și încarcă modelul gpt-oss:20b necesar agentului. Această imagine expune portul utilizat de serviciul Ollama și permite încărcarea automată a modelului la pornirea containerului.

Serverul MCP a fost mutat într-o imagine separată care pornește aplicația pe portul 8001 și folosește protocolul HTTP Streaming. Pe lângă funcționalitățile implementate în etapa precedentă, aici a fost adăugat și un mecanism de autentificare. Token-urile sunt verificate la fiecare request, conform documentației oficiale a MCP pentru autorizare. Pentru gestionarea autentificării am utilizat Keycloak, care emite token-uri JWT ce sunt validate în containerul MCP înainte ca un agent să poată folosi tool-urile serverului.

Pentru interfața și clientul local, a fost creată o imagine ce include ADK-Web și agentul implementat anterior. Agentul este configurat să folosească hostname-ul containerului MCP în locul unei adrese locale, astfel încât comunicarea să funcționeze corect în interiorul rețelei Docker.

Toate imaginile au fost integrate într-un fișier docker-compose ce definește rețeaua internă, dependențele dintre servicii și volumele necesare pentru persistența modelelor Ollama și a fișierelor gestionate de MCP. Odată

pornit, intregul sistem se conecteaza automat: ADK-Web comunica cu agentul, agentul cu serverul MCP, iar MCP cu modelul Ollama.

Probleme intampinate si modul de rezolvare

Cea mai dificila parte a fost configurarea corecta a Dockerfile-urilor. Initial, containerele nu porneau corespunzator, fie din cauza unor rute gresite, fie din cauza unor porturi incorect expuse. Am rezolvat aceste probleme prin testarea individuala a fiecărei imagini si standardizarea structurii directoarelor.

Integrarea autentificarii a fost o alta provocare. Comunicarea cu Keycloak nu functiona corect la inceput, deoarece serverul MCP nu reusea sa valideze token-urile. Am ajustat configuratiile Keycloak (realm, client, permisiuni) si am adaugat o logica suplimentara in middleware-ul MCP pentru a trata cazurile in care Keycloak nu era inca disponibil la pornirea containerelor.

Concluzii

Aceasta etapa a proiectului a dus la transformarea arhitecturii initiale intr-un sistem modular si complet containerizat. Am invatat sa construiesc imagini Docker eficiente, sa configurez retele interne in docker-compose si sa integrez un mecanism de autentificare bazat pe token-uri pentru un server MCP. Totodata, am deprins abilitati practice legate de depanare, sincronizarea serviciilor si comunicatia dintre containere.